

Seminarski rad

Klasifikacija muzičkih numera

Projekat iz Istraživanja podataka 2 [R275]

Mentor:

Prof. dr Mirjana Maljković Ružičić

Student:

Mina Živić 240/2019

Mart 2026.

Sadržaj:

1. Uvod	3
1.1 Opis problema	3
1.2 Učitavanje podataka	3
2. Filtriranje i obrada podataka.....	4
2.1 Spajanje tabele features i tracks	4
2.2 Dodavanje tagova.....	5
2.3 Biranje ciljne promenljive	6
2.4 Parsiranje tagova.....	6
2.5 Podela skupova podataka na trening i test skup.....	6
2.6 Redukcija dimenzionalnosti.....	7
3. Algoritmi klasifikacije.....	8
3.1 LightGBM.....	8
3.2 Random Forest	10
3.3 ExtraTreesClassifier	15
3.4 HistGradientBoosting.....	16
3.5 LinearSVC.....	17
3.6 LogisticRegression	18
4. Zaključak	19

1. Uvod

1.1 Opis problema

Razvoj digitalnih tehnologija i interneta doveo je do ogromnog rasta količine multimedijalnih podataka, posebno u oblasti muzike. U takvom okruženju javlja se potreba za automatskom analizom i organizacijom muzičkih podataka, kako bi korisnici mogli efikasno da pretražuju, klasifikuju i preporučuju muziku. Jedan od ključnih problema u analizi muzičkih podataka jeste automatska klasifikacija muzičkih žanrova. Muzički žanr predstavlja kategoriju koja opisuje stil i karakteristike određene muzike, kao što su ritam, instrumentacija, tempo, struktura kompozicije i druge akustičke osobine. U ovom projektu koristi se FMA (Free Music Archive) dataset, koji predstavlja jedan od poznatih skupova podataka za analizu muzike. Ovaj dataset sadrži veliki broj audio zapisa zajedno sa audio karakteristikama i metapodacima, uključujući žanrove i tagove. Kombinovanjem numeričkih audio karakteristika i tekstualnih informacija moguće je izgraditi modele koji preciznije klasifikuju muziku u odgovarajuće žanrove. Cilj ovog rada je da se primenom metoda mašinskog učenja i obrade podataka razviju modeli koji mogu automatski da klasifikuju muzičke zapise na osnovu njihovih karakteristika.

1.2 Učitavanje podataka

Skup podataka koji se koristi u istraživanju sastoji se iz dva glavna dela:

- Numeričke audio karakteristike (features)
- Metapodaci o pesmama (tracks)

Prvi izazov odnosi se na veliki broj atributa. Audio karakteristike često generišu stotine ili hiljade numeričkih kolona, što dovodi do problema visoke dimenzionalnosti. Visoka dimenzionalnost može negativno uticati na performanse modela, povećati vreme treniranja i dovesti do pojave preprilagođavanja (overfitting). Zbog toga je potrebno primeniti metode redukcije dimenzionalnosti i selekcije atributa.

Drugi izazov odnosi se na obradu tekstualnih podataka. Tekstualni tagovi ne mogu se direktno koristiti u algoritmima mašinskog učenja, već ih je potrebno transformisati u numerički oblik. U ovom radu tekstualni podaci se obrađuju korišćenjem TF-IDF vektorizacije, čime se svaki tekstualni opis pretvara u numerički vektor koji opisuje značaj pojedinih reči u skupu podataka.

Treći izazov predstavlja balansiranost klasa. U realnim datasetovima često postoji neravnomerna distribucija žanrova, gde su neki žanrovi znatno zastupljeniji od drugih. Ovakva neravnoteža može dovesti do toga da modeli favorizuju dominantne klase. Zbog toga je potrebno primeniti odgovarajuće tehnike treniranja modela koje uzimaju u obzir balans klasa. U okviru ovog istraživanja rešava se sledeći problem:

Na osnovu numeričkih audio karakteristika i tekstualnih tagova potrebno je razviti modele mašinskog učenja koji mogu automatski da klasifikuju muzičke zapise u odgovarajuće muzičke žanrove.

U radu se ispituju različiti pristupi: treniranje modela nad svim atributima, treniranje modela nad redukovanim skupovima atributa, korišćenje različitih algoritama klasifikacije i poređenje performansi modela.

Cilj je da se utvrdi koji pristup daje najbolje rezultate u pogledu tačnosti klasifikacije, kao i da se analizira uticaj različitih metoda obrade podataka na kvalitet modela.

2. Filtriranje i obrada podataka

2.1 Spajanje tabele features i tracks

Pre nego što je moguće primeniti algoritme mašinskog učenja nad skupom podataka, neophodno je izvršiti odgovarajuću obradu podataka. Mogu sadržati nedostajuće vrednosti, nepotrebne kolone ili informacije koje nisu direktno pogodne za analizu. Proces obrade podataka obuhvata nekoliko koraka, među kojima su spajanje različitih tabela, izbor relevantnih atributa, obrada tekstualnih informacija i definisanje ciljne promenljive za klasifikaciju. Najvažnije tabele koje se koriste u ovom radu su: features – tabela koja sadrži numeričke audio karakteristike pesama, tracks – tabela koja sadrži metapodatke o pesmama, uključujući žanrove i tagove.

Pošto se informacije o jednoj pesmi nalaze u više tabela, potrebno je izvršiti njihovo spajanje kako bi se dobio jedinstven skup podataka pogodan za dalju analizu. Tabela features sadrži veliki broj numeričkih atributa koji opisuju audio signal pesme.

Ove karakteristike su prethodno izračunate iz audio zapisa i predstavljaju različite statističke i signalne osobine zvuka. Među njima se nalaze karakteristike poput:

- MFCC (Mel-Frequency Cepstral Coefficients) – predstavljaju spektarske karakteristike zvuka i često se koriste u analizi govora i muzike
- Chroma karakteristike – opisuju raspodelu energije po različitim tonovima u muzičkoj skali
- Spectral features – opisuju raspodelu frekvencija u audio signalu.
- Statističke mere uključuju srednju vrednost, minimum, maksimum i standardnu devijaciju.

Ove karakteristike omogućavaju da se kompleksni audio signal predstavi kroz numeričke vrednosti koje algoritmi mašinskog učenja mogu da analiziraju. Više o njima je obrađeno kasnije.

Sa druge strane, tabela tracks sadrži metapodatke o pesmama. Ovi metapodaci uključuju informacije kao što su: naziv pesme, izvođač, žanr pesme, različiti opisni tagovi.

Pošto su numeričke karakteristike i metapodaci razdvojeni u dve različite tabele, neophodno je izvršiti njihovo spajanje (join). Spajanje se vrši na osnovu identifikatora pesme koji postoji u obe tabele. U ovom radu koristi se inner join, čime se zadržavaju samo one pesme koje imaju i audio karakteristike i odgovarajuće metapodatke. Na ovaj način se dobija jedinstvena tabela u kojoj svaki red predstavlja jednu pesmu, dok kolone predstavljaju različite karakteristike te pesme. Nakon spajanja tabela, dataset sadrži veliki broj numeričkih atributa iz tabele features, kao i dodatne informacije iz tabele tracks. Ovaj objedinjeni skup podataka predstavlja osnovu za dalju obradu i izgradnju modela klasifikacije.

2.2 Dodavanje tagova

Tagovi predstavljaju opisne oznake koje korisnici ili autori dodeljuju pesmama kako bi opisali njihov stil, raspoloženje ili druge karakteristike.

TF-IDF metoda omogućava da se tekstualni podaci pretvore u numeričke vektore koji opisuju značaj pojedinih reči u dokumentima. U ovom slučaju, svaki skup tagova posmatra se kao dokument, dok se pojedinačni tagovi posmatraju kao reči.

Rezultat ove transformacije je matrica u kojoj: svaki red predstavlja jednu pesmu, svaka kolona predstavlja jedan tag, vrednost u matrici predstavlja značaj tog taga za određenu pesmu.

2.3 Biranje ciljne promenljive

U problemima klasifikacije neophodno je definisati ciljnu promenljivu (target variable), odnosno atribut koji model treba da predvidi. U ovom projektu ciljna promenljiva predstavlja muzički žanr pesme, koji se nalazi u koloni `genre_top` u tabeli `tracks`. Ova kolona sadrži osnovnu klasifikaciju pesme u jedan od nekoliko muzičkih žanrova. Primeri žanrova koji se mogu pojaviti u datasetu uključuju:

- Rock
- Electronic
- Hip-Hop
- Pop
- Folk
- Jazz
- Experimental

2.4 Parsiranje tagova

Tagovi su u datasetu često zapisani kao tekstualna reprezentacija liste. Prvi korak je pretvaranje ovog zapisa u stvarnu listu elemenata. Na taj način se dobija struktura u kojoj svaki tag može biti obrađen pojedinačno. Uklanjanje nepotrebnih karaktera: Tokom obrade uklanjaju se različiti nepotrebni karakteri koji nemaju semantičko značenje za klasifikaciju, kao što su: specijalni simboli, brojevi koji ne nose značenje, nepotrebni razmaci. Cilj ovog koraka je da se zadrže samo tagovi koji nose informaciju o karakteristikama pesme.

2.5 Podela skupova podataka na trening i test skup

Nakon pripreme podataka sledeći važan korak je podela skupa podataka na trening i test skup.

Trening skup predstavlja deo podataka koji se koristi za učenje modela. Tokom treniranja model analizira ulazne karakteristike i odgovarajuće ciljne vrednosti kako bi pronašao obrasce koji povezuju te karakteristike sa klasama.

Test skup predstavlja deo podataka koji nije korišćen tokom treniranja modela. On se koristi za procenu performansi modela nakon treniranja.

Pošto se radi o problemu klasifikacije, važno je da raspodela klasa bude približno ista u trening i test skupu. Zbog toga se koristi stratifikovana podela podataka, koja osigurava da proporcija različitih žanrova ostane približno ista u oba skupa.

2.6 Redukcija dimenzionalnosti

U ovom projektu koriste se dve metode:

- SelectKBest
- PCA (Principal Component Analysis)

SelectKBest

SelectKBest predstavlja metodu selekcije atributa koja bira određeni broj najrelevantnijih atributa na osnovu statističkog kriterijuma. U ovom radu koristi se statistička funkcija `f_classif`, koja meri povezanost između svakog atributa i ciljne promenljive. Za svaki atribut računa se F-statistika koja pokazuje koliko je taj atribut značajan za razlikovanje klasa. Nakon izračunavanja vrednosti bira se određeni broj atributa sa najvećim F-vrednostima. Na taj način se eliminišu manje značajni atributi i zadržavaju samo oni koji najviše doprinose klasifikaciji. Prednosti ove metode uključuju: smanjenje dimenzionalnosti skupa podataka, brže treniranje modela, uklanjanje neinformativnih atributa

PCA (Principal Component Analysis)

PCA predstavlja metodu linearne transformacije podataka koja smanjuje dimenzionalnost tako što originalne attribute transformiše u novi skup atributa koji se nazivaju glavne komponente. Glavne komponente su konstruisane tako da: prva komponenta zadržava najveću varijansu u podacima, svaka naredna komponenta zadržava što više preostale varijanse. Na taj način moguće je predstaviti podatke u manjem broju dimenzija uz minimalni gubitak informacija. U ovom projektu PCA se koristi i za vizuelizaciju podataka, gde se visoko-dimenzionalni podaci projektuju u

dve ili tri dimenzije kako bi se lakše analizirala struktura dataset-a. Prednosti PCA metode uključuju: značajno smanjenje dimenzionalnosti, uklanjanje korelisanih atributa, lakšu vizuelizaciju podataka. Međutim, jedna od mana PCA metode jeste to što nove komponente više nemaju direktno interpretabilno značenje kao originalni atributi.

3. Algoritmi klasifikacije

3.1 LightGBM

U ovom radu za klasifikaciju muzičkih žanrova korišćen je algoritam LightGBM (Light Gradient Boosting Machine). LightGBM predstavlja jedan od savremenih algoritama mašinskog učenja zasnovanih na metodi gradijentnog pojačavanja (Gradient Boosting) i često se koristi u problemima klasifikacije i regresije zbog svoje visoke efikasnosti i dobre skalabilnosti. Gradient Boosting je tehnika koja kombinuje više jednostavnih modela (najčešće stabala odlučivanja) kako bi se dobio jedan snažniji model. Ideja algoritma je da se modeli treniraju sekvencijalno, pri čemu svaki novi model pokušava da ispravi greške prethodnih modela. LightGBM je optimizovana implementacija ove metode koja koristi napredne tehnike za ubrzavanje treniranja modela i smanjenje potrošnje memorije. Zbog toga se često koristi kod velikih datasetova i problema sa velikim brojem atributa. U ovom projektu korišćena su dva modela: model treniran nad celim skupom atributa, model treniran nad redukovanim skupom atributa. Na ovaj način moguće je analizirati uticaj redukcije dimenzionalnosti na performanse modela.

Model je definisan korišćenjem sledećih parametara:

```
lgbm = LGBMClassifier(  
    n_estimators=400,  
    learning_rate=0.05,  
    max_depth=-1,  
    num_leaves=64,  
    subsample=0.8,  
    colsample_bytree=0.8  
)
```


Parametar `n_estimators` određuje broj stabala odlučivanja koja će model izgraditi tokom treniranja. U ovom slučaju vrednost je postavljena na 400, što znači da model koristi 400 stabala. Veći broj stabala obično omogućava modelu da bolje nauči složene obrasce u podacima, ali istovremeno povećava vreme treniranja.

Parametar `learning_rate` određuje koliko svako novo stablo doprinosi ukupnom modelu. U ovom projektu vrednost je postavljena na 0.05, što znači da svaki novi model ima relativno mali uticaj na konačni rezultat. Manja vrednost `learning_rate` često dovodi do stabilnijeg treniranja i bolje generalizacije modela, ali zahteva veći broj stabala kako bi model postigao dobre rezultate.

Parametar `max_depth` određuje maksimalnu dubinu stabala odlučivanja. U ovom slučaju vrednost je -1, što znači da dubina stabla nije ograničena. Neograničena dubina omogućava modelu da uči složenije obrasce u podacima, ali može povećati rizik od overfitting-a, odnosno preprilagođavanja modela trening podacima.

Parametar `num_leaves` određuje maksimalan broj listova u jednom stablu odlučivanja. U ovom modelu vrednost je 64, što znači da svako stablo može imati do 64 lista. Broj listova direktno utiče na kompleksnost modela. Veći broj listova omogućava modelu da hvata složenije obrasce u podacima, ali takođe može povećati rizik od preprilagođavanja.

Parametar `subsample` određuje koliki procenat podataka se koristi prilikom treniranja svakog stabla. U ovom slučaju koristi se 80% podataka (0.8). Ovaj pristup uvodi određeni stepen slučajnosti u proces treniranja i može pomoći u smanjenju overfitting-a.

Parametar `colsample_bytree` određuje koliki procenat atributa se koristi prilikom izgradnje svakog stabla. Vrednost 0.8 znači da se za svako stablo koristi 80% atributa. Ova tehnika takođe doprinosi smanjenju overfitting-a i povećava robusnost modela.

Nakon treniranja modela LightGBM nad pripremljenim skupom podataka izvršena je evaluacija performansi modela na test skupu. Evaluacija je izvršena korišćenjem metrike tačnosti klasifikacije (accuracy), koja predstavlja odnos broja tačno klasifikovanih primera i ukupnog broja primera u test skupu. U ovom istraživanju trenirana su dva modela: model treniran nad celim skupom atributa (ALL) model treniran nad redukovanim skupom atributa (RED) Rezultati klasifikacije su sledeći:

- LightGBM ALL accuracy: 0.7445
- LightGBM RED accuracy: 0.7428

Ovi rezultati pokazuju da je model treniran nad celim skupom atributa ostvario nešto bolju tačnost klasifikacije u odnosu na model treniran nad redukovanim skupom atributa.

Razlog zbog kojeg model treniran nad celim skupom atributa postiže blago bolje rezultate može biti u tome što koristi veću količinu informacija iz podataka.

3.2 Random Forest

Random Forest pripada grupi ensemble metoda, što znači da kombinuje veliki broj pojedinačnih modela kako bi se dobio stabilniji i precizniji rezultat. Osnovna ideja Random Forest algoritma je da se izgradi veliki broj stabala odlučivanja (decision trees), pri čemu svako stablo donosi svoju predikciju. Konačna klasifikacija dobija se glasanjem svih stabala u šumi. Ovakav pristup smanjuje varijansu modela i povećava robusnost u odnosu na pojedinačno stablo odlučivanja.

```
rf = RandomForestClassifier(  
    n_estimators=600,  
    max_depth=None,  
    min_samples_split=4,  
    class_weight="balanced",  
    n_jobs=-1  
)
```

Parametar `n_estimators` određuje broj stabala odlučivanja u šumi. U ovom slučaju koristi se 600 stabala, što omogućava modelu da bolje nauči obrasce u podacima. Veći broj stabala obično poboljšava stabilnost modela, ali povećava vreme treniranja. Parametar `max_depth` određuje maksimalnu dubinu stabla odlučivanja. Vrednost `None` znači da dubina stabla nije ograničena. Ovo omogućava modelu da pronađe složenije obrasce u podacima, ali može povećati rizik od preprilagođavanja modela trening podacima.

Parametar `min_samples_split` određuje minimalan broj uzoraka koji je potreban da bi se čvor stabla podelio na dva nova čvora. U ovom slučaju vrednost je 4, što znači da je potrebno najmanje četiri uzorka da bi se izvršila podela. Ovaj parametar pomaže u kontroli kompleksnosti modela i sprečava stvaranje veoma malih čvorova.

Parametar `class_weight="balanced"` koristi se kada dataset nije potpuno balansiran. Ova opcija automatski prilagođava težine klasa tako da manje zastupljene klase dobiju veću težinu tokom treniranja modela. Na taj način model obraća više pažnje na retke klase.

Parametar `n_jobs=-1` omogućava korišćenje svih dostupnih procesorskih jezgara tokom treniranja modela. Pošto Random Forest trenira veliki broj stabala, paralelizacija značajno ubrzava proces treniranja.

Random Forest model treniran je u tri varijante:

- nad celim skupom atributa
- nad redukovanim skupom atributa
- nad skupom najboljih atributa (best features)

Rezultati klasifikacije su sledeći:


- RandomForest ALL accuracy: 0.6336
- RandomForest RED accuracy: 0.6378
- RandomForest BEST accuracy: 0.6410

Nakon toga je formiran novi dataset koji sadrži samo ove najvažnije attribute: Best features shape: (39276, 600)

To znači da dataset sada sadrži: 39276 primera, 600 najvažnijih atributa

```
importances = rf.feature_importances_  
indices = np.argsort(importances)[:, -1][:600]
```

Najbolji rezultat postignut je korišćenjem 600 najvažnijih atributa, što pokazuje da selekcija atributa može imati pozitivan uticaj na performanse modela. Iako razlike u tačnosti nisu velike, redukcija atributa doprinosi efikasnijem modelu i može smanjiti kompleksnost modela.



MFCC predstavlja skup karakteristika koje opisuju frekvencijsku strukturu audio signala. Ove karakteristike su veoma popularne u analizi zvuka, posebno u oblastima kao što su:

- prepoznavanje govora
- klasifikacija muzike
- audio analiza

MFCC koristi Mel frekvencijsku skalu, koja je prilagođena načinu na koji ljudsko uho percipira zvuk. Ljudsko uho bolje razlikuje promene u nižim frekvencijama nego u višim, a Mel skala upravo modeluje ovu osobinu

`mfcc__max__04` – maksimalna vrednost četvrtog MFCC koeficijenta

`mfcc__mean__04` – srednja vrednost četvrtog MFCC koeficijenta

`mfcc__median__01` – medijana prvog MFCC koeficijenta

Broj na kraju predstavlja indeks MFCC koeficijenta, dok deo imena kao što su `max`, `mean` ili `median` predstavlja statističku meru tog koeficijenta kroz ceo audio zapis.

MSE (Mean Squared Energy)

U datasetu se pojavljuju atributi kao što su:

`mse__mean__01`

`mse__median__01`

`mse__std__01`

Ovde `mse` predstavlja meru energije audio signala, odnosno količinu energije ili intenziteta zvuka u određenom delu signala.

U kontekstu audio karakteristika, MSE opisuje snagu signala i može pomoći u razlikovanju različitih tipova muzike. Na primer:

- elektronska muzika često ima konstantno visoku energiju
- ambijentalna muzika ima nižu energiju
- rok muzika može imati velike promene u energiji tokom pesme.

Statističke vrednosti koje se pojavljuju u nazivima atributa imaju sledeće značenje:

- mean – prosečna vrednost energije
- median – medijana energije
- std – standardna devijacija energije

Ove vrednosti opisuju kako se energija zvuka menja tokom trajanja pesme

spectral_contrast__median__03

spectral_contrast__mean__04

Spectral contrast predstavlja meru razlike između najjačih i najslabijih frekvencija u audio signalu. Ova karakteristika opisuje strukturu frekvencijskog spektra i može pomoći u razlikovanju različitih muzičkih stilova. Na primer:

- rok muzika često ima veliki kontrast između basa i visokih frekvencija
- ambijentalna muzika može imati ravnomerniji spektar

Zaključak analize najvažnijih atributa

Analiza grafikona pokazuje da najveći uticaj na klasifikaciju imaju frekvencijske karakteristike audio signala, posebno MFCC koeficijenti. To znači da model najviše koristi informacije koje opisuju:

- raspodelu frekvencija
- harmonijske karakteristike muzike
- energiju audio signala.

Rezultati analize potvrđuju da su MFCC i spektralne karakteristike ključni atributi za automatsku klasifikaciju muzike.

Chroma karakteristike

Druga grupa važnih atributa su chroma karakteristike. Chroma karakteristike opisuju raspodelu energije po različitim tonovima muzičke skale. Ove karakteristike su povezane sa harmonijom i tonalitetom pesme. Pošto različiti muzički žanrovi koriste različite harmonske strukture, chroma karakteristike mogu pomoći modelu da razlikuje određene stilove muzike.

Na primer:

- rok muzika često ima izražene akorde i harmonijske progresije
- elektronska muzika može imati drugačiju raspodelu tonalnih elemenata

Zbog toga chroma atributi mogu imati značajan uticaj na klasifikaciju.

Spektralne karakteristike

Među važnim atributima često se pojavljuju i spektralne karakteristike, koje opisuju raspodelu frekvencija u audio signalu. Ove karakteristike mogu opisivati:

- energiju signala
- širinu frekvencijskog spektra
- dominaciju određenih frekvencija

Različiti muzički žanrovi imaju različite akustičke profile. Na primer, elektronska muzika često ima izražen bas i sintetičke zvuke, dok akustična muzika ima drugačiju raspodelu frekvencija. Spektralne karakteristike omogućavaju modelu da prepozna ove razlike.

3.3 ExtraTreesClassifier

U ovom radu korišćen je i algoritam Extra Trees (Extremely Randomized Trees) za klasifikaciju muzičkih žanrova. Extra Trees pripada grupi ensemble metoda zasnovanih na stablima odlučivanja, slično algoritmu Random Forest. Osnovna ideja Extra Trees algoritma je da se izgradi veliki broj stabala odlučivanja i da se njihove predikcije kombinuju kako bi se dobio konačan rezultat. Međutim, za razliku od Random Forest algoritma, Extra Trees uvodi još veći stepen slučajnosti prilikom izgradnje stabala. Kod Random Forest algoritma najbolja podela čvora bira se među slučajnim podskupom atributa, dok Extra Trees algoritam dodatno uvodi slučajnost tako što: bira slučajne pragove (thresholds) za podelu atributa koristi slučajne podskupove atributa. Zbog toga Extra Trees algoritam često trenira brže i može smanjiti varijansu modela.

```
et = ExtraTreesClassifier( n_estimators=400, max_depth=None,  
min_samples_split=5, min_samples_leaf=2, max_features="sqrt",  
random_state=42, n_jobs=-1 )
```

Mnoge parametre smo već razmatrali ovde je jedini novi parametar `min_samples_leaf` određuje minimalan broj uzoraka koji mora postojati u listu stabla. Vrednost 2 znači da svaki list mora sadržati najmanje dva uzorka. Ovo sprečava stvaranje veoma malih listova i doprinosi stabilnosti modela.

Parametar `max_features="sqrt"` određuje koliko atributa se razmatra prilikom svake podele čvora. Opcija `sqrt` znači da se koristi kvadratni koren od ukupnog broja atributa. Ovaj pristup uvodi dodatnu slučajnost i smanjuje korelaciju između stabala.

Analiza rezultata : Model treniran nad celim skupom atributa ostvario je tačnost od 0.6338, što znači da je približno 63.38% pesama pravilno klasifikovano. Model treniran nad redukovanim skupom atributa ostvario je nešto bolji rezultat od 0.6370, odnosno 63.70% tačno klasifikovanih primera. Razlika između ova dva modela je relativno mala, ali pokazuje da redukcija dimenzionalnosti može imati pozitivan uticaj na performanse modela. Uklanjanjem manje značajnih atributa model dobija jednostavniji skup podataka koji može olakšati proces učenja i smanjiti uticaj šuma u podacima.

3.4 HistGradientBoosting

U ovom projektu korišćen je i algoritam `HistGradientBoostingClassifier`, koji predstavlja jednu od modernih implementacija Gradient Boosting algoritma dostupnu u biblioteci `scikit-learn`. Gradient Boosting je metoda ansambla (ensemble method) koja kombinuje veliki broj slabijih modela, najčešće stabala odlučivanja, kako bi se dobio jedan snažniji model. Ideja algoritma je da se modeli treniraju sekvencijalno, pri čemu svaki sledeći model pokušava da ispravi greške prethodnog modela. `HistGradientBoosting` predstavlja optimizovanu verziju ovog algoritma koja koristi histogram pristup za obradu podataka. Umesto da se svaka vrednost atributa posebno razmatra, algoritam prvo grupiše vrednosti u određeni broj intervala (histogram binova). Ovaj pristup značajno ubrzava treniranje modela i smanjuje potrošnju memorije. Zbog ovih karakteristika `HistGradientBoosting` je posebno efikasan kod datasetova koji sadrže veliki broj uzoraka i atributa.

```
gb = HistGradientBoostingClassifier(  
    max_iter=200,  
    max_depth=12  
)
```

Analiza rezultata Model treniran nad celim skupom atributa ostvario je tačnost od 0.7278, odnosno približno 72.78% tačno klasifikovanih primera. Sa druge strane, model treniran nad redukovanim skupom atributa ostvario je nešto nižu tačnost od 0.7174, što predstavlja 71.74% tačno klasifikovanih primera. Razlika između ova dva rezultata iznosi oko 1%, što znači da model treniran nad celim skupom atributa koristi dodatne informacije koje su izgubljene tokom procesa redukcije dimenzionalnosti. Redukcija dimenzionalnosti uklanja deo atributa koji imaju manji uticaj na klasifikaciju, ali je moguće da su neki od tih atributa ipak sadržali određenu količinu korisnih informacija.

3.5 LinearSVC

Pre primene algoritma SVM (Support Vector Machine) izvršeno je skaliranje ulaznih podataka korišćenjem metode StandardScaler. Skaliranje podataka je važan korak u mnogim algoritmima mašinskog učenja, posebno kod algoritama koji zavise od udaljenosti između podataka ili optimizacije u višedimenzionalnom prostoru.

Za klasifikaciju muzičkih žanrova korišćen je algoritam Support Vector Machine (SVM), tačnije njegova linearna verzija LinearSVC. SVM je jedan od najpoznatijih algoritama za klasifikaciju koji funkcioniše tako što pokušava da pronađe optimalnu hiperravan (hyperplane) koja razdvaja podatke različitih klasa u višedimenzionalnom prostoru. Osnovna ideja algoritma je da pronađe granicu između klasa koja ima najveći mogući razmak (margin) između najbližih tačaka različitih klasa. Ove najbliže tačke nazivaju se support vectors, po čemu je algoritam dobio ime.

```
svm = LinearSVC(  
    C=2,  
    class_weight="balanced",  
    max_iter=5000  
)
```

Parametar C predstavlja regularizacioni parametar koji kontroliše kompromis između: širine margine i grešaka klasifikacije na trening podacima. Veća vrednost parametra C znači da model pokušava da smanji broj grešaka na trening podacima, čak i po cenu manje margine. U ovom slučaju korišćena je vrednost $C = 2$, što omogućava modelu da pronađe balans između generalizacije i tačnosti.

Parametar `class_weight="balanced"` koristi se kada dataset nije potpuno balansiran po klasama.

Model treniran nad celim skupom atributa ostvario je tačnost od 0.6778, odnosno približno 67.78% tačno klasifikovanih primera. Sa druge strane, model treniran nad redukovanim skupom atributa ostvario je nešto nižu tačnost od 0.6615, odnosno 66.15% tačno klasifikovanih primera. Razlika između ova dva rezultata iznosi približno 1.6 procentnih poena, što pokazuje da je model treniran nad celim skupom atributa uspeo da iskoristi dodatne informacije koje su izgubljene tokom procesa redukcije dimenzionalnosti.

3.6 LogisticRegression


U ovom projektu korišćen je i algoritam Logistic Regression za klasifikaciju muzičkih žanrova. Logistička regresija predstavlja jedan od osnovnih i najčešće korišćenih algoritama za rešavanje problema klasifikacije u mašinskom učenju. Iako naziv sadrži reč „regresija“, ovaj algoritam se primarno koristi za klasifikaciju. Logistička regresija modeluje verovatnoću pripadnosti određenoj klasi koristeći logističku (sigmoid) funkciju. Rezultat modela je verovatnoća da dati primer pripada određenoj klasi, a klasifikacija se dobija izborom klase sa najvećom verovatnoćom. U problemima sa više klasa, kao što je klasifikacija muzičkih žanrova u ovom radu, logistička regresija koristi strategiju one-vs-rest, gde se trenira poseban model za svaku klasu.

```
logreg = LogisticRegression(  
    max_iter=2000,  
    solver="saga",  
    n_jobs=-1,  
    class_weight="balanced"  
)
```

Parametar solver="saga" određuje algoritam koji se koristi za optimizaciju modela. SAGA solver je posebno pogodan za: velike datasetove visokodimenzionalne podatke sparse matrice (kao što su TF-IDF reprezentacije) Zbog toga je ovaj solver dobar izbor za dataset koji sadrži veliki broj audio i tekstualnih atributa.

Model treniran nad celim skupom atributa ostvario je tačnost od 0.6389, odnosno približno 63.89% tačno klasifikovanih primera. Model treniran nad redukovanim skupom atributa ostvario je nešto nižu tačnost od 0.6295, odnosno 62.93% tačno klasifikovanih primera. Razlika između ova dva modela iznosi približno 1%, što pokazuje da model treniran nad celim skupom atributa koristi dodatne informacije koje su izgubljene tokom redukcije dimenzionalnosti. Pošto je logistička regresija linearni model, veći broj atributa može pomoći modelu da pronađe bolju linearnu granicu između klasa.


4. Zaključak



Na grafiku je prikazano poređenje performansi različitih algoritama mašinskog učenja koji su korišćeni za klasifikaciju muzičkih žanrova. Grafikon prikazuje tačnost klasifikacije (accuracy) za svaki model na test skupu podataka.

Najveću tačnost ostvario je LightGBM model, dok su nešto slabije rezultate postigli RandomForest, ExtraTrees i Logistic Regression modeli.

Model LightGBM ostvario je najbolju tačnost klasifikacije od približno 74.45%, što znači da je uspešno klasifikovao najveći broj pesama iz test skupa. Drugi najbolji model je HistGradientBoosting, sa tačnošću od približno 72.78%. Ova dva modela pripadaju grupi gradient boosting algoritama, koji treniraju modele sekvencijalno i pokušavaju da isprave greške prethodnih modela. Zbog ovog pristupa oni mogu bolje da modeluju složene odnose između atributa u datasetu. Model SVM ostvario je srednje dobre rezultate sa tačnošću od približno 67.78%. SVM koristi linearnu granicu razdvajanja između klasa, zbog čega može imati poteškoće u modelovanju složenih nelinearnih odnosa u podacima. Modeli RandomForest i ExtraTrees ostvarili su slične rezultate, sa tačnošću od oko 63–64%. Iako su ovi modeli robusni i često daju dobre rezultate, u ovom problemu nisu uspeli da dostignu performanse gradient boosting algoritama. Logistic Regression ostvarila je tačnost od oko 63.89%, što je očekivano za linearni model koji koristi jednostavniju granicu razdvajanja između klasa.



Analiza konfuzione matrice

Na slici je prikazana normalizovana konfuziona matrica (Normalized Confusion Matrix) za model HistGradientBoosting treniran nad celim skupom atributa. Konfuziona matrica predstavlja jedan od najvažnijih alata za analizu performansi modela klasifikacije jer pokazuje kako model klasifikuje svaku pojedinačnu klasu. Na vertikalnoj osi nalaze se stvarne klase (True label), dok se na horizontalnoj osi nalaze predviđene klase (Predicted label).

Vrednosti na glavnoj dijagonali predstavljaju tačno klasifikovane primere, dok vrednosti van dijagonale predstavljaju pogrešne klasifikacije, odnosno situacije kada model pogrešno predvidi žanr pesme. Pošto je matrica normalizovana, vrednosti predstavljaju procenat klasifikacije za svaku klasu.

Na osnovu matrice može se uočiti da model veoma dobro prepoznaje sledeće žanrove:

- Old-Time / Historic – 0.89 Ovaj žanr ima najveću tačnost klasifikacije. Razlog za to može biti činjenica da ovaj tip muzike ima veoma specifične audio karakteristike, kao što su akustični instrumenti i specifična frekvencijska struktura.
- Rock – 0.86 Rock muzika takođe ima visoku stopu tačne klasifikacije. Rock često ima izražene gitare i karakterističan ritam, što se jasno odražava u audio karakteristikama poput MFCC i spektralnih atributa.

- Classical – 0.83 Klasična muzika je takođe relativno dobro klasifikovana jer ima specifične harmonijske i instrumentalne karakteristike koje se razlikuju od modernih muzičkih žanrova.
- Experimental – 0.79 Eksperimentalna muzika pokazuje relativno visoku tačnost jer često ima jedinstvene zvučne strukture koje se razlikuju od standardnih muzičkih stilova.

Konfuziona matrica pokazuje da model ima najviše problema sa sledećim klasama:

- Instrumental - Tačnost klasifikacije ove klase je relativno niska (oko 0.33). Model često meša instrumentalnu muziku sa drugim žanrovima kao što su: Experimental i Electronic. Razlog za to može biti činjenica da instrumentalna muzika nema vokale, ali slične karakteristike mogu imati i drugi žanrovi, zbog čega model ima poteškoće u njihovom razlikovanju.
- Jazz - ima relativno nisku tačnost klasifikacije (oko 0.32). Model često pogrešno klasifikuje jazz kao: Experimental i Rock
Mogućnost za to može biti kompleksna struktura jazz-a koja uključuje improvizaciju, različite instrumentalne elemente i promenljive ritmičke obrasce. Ove karakteristike mogu biti slične eksperimentalnoj muzici, dok prisustvo instrumenata kao što su gitare i određeni ritmički obrasci može dovesti do zabune sa rock muzikom.
- Pop - muzika takođe ima relativno nisku tačnost klasifikacije (oko 0.27). Model često meša pop sa sledećim žanrovima: Rock i Electronic
Mogućnost za to je što pop muzika često deli slične produkcijske karakteristike sa drugim modernim žanrovima, kao što su elektronski ritmovi, sintetički zvukovi i gitarski aranžmani. Zbog ovih sličnosti model može imati poteškoće u jasnom razlikovanju pop muzike od srodnih žanrova.
- Spoken Klasa - ima najnižu tačnost klasifikacije (oko 0.21). Model često pogrešno klasifikuje spoken sadržaj kao: Experimental i Rock
Spoken audio zapisi uglavnom sadrže govor bez jasne muzičke strukture. Zbog toga njihove akustičke karakteristike mogu biti slične eksperimentalnim audio zapisima ili određenim instrumentalnim delovima u drugim muzičkim žanrovima.